Método dos Mínimos Quadrados e Integração Numérica

Prof. Dr. Ivan Mezzomo

PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA - PPGEE/UFERSA

FUNDAMENTOS DE MODELAGEM COMPUTACIONAL

Introdução

- Quando um erro substancial estiver associado aos dados, a interpolação polinomial é inapropriada e pode produzir resultados insatisfatórios quando usada para prever valores intermediários.
- Muitas observações científicas são feitas em experimentos nos quais grandezas físicas são medidas e gravadas.
- Tais registros são normalmente chamados de dados ou pontos experimentais.
- Dados experimentais frequentemente são usados no desenvolvimento de fórmulas matemáticas que possam representá-los.
- Uma estratégia mais adequada para tais casos seria determinar uma função aproximadora que ajustasse a forma ou tendência geral dos dados sem necessariamente passar pelos pontos individuais.

Introdução

- Para remover essa subjetividade, podemos determinar uma curva que minimize a discrepância entre os dados e os pontos da curva.
- Uma técnica para conseguir esse objetivo é chamada **Método dos Mínimos Quadrados (MMQ)**.

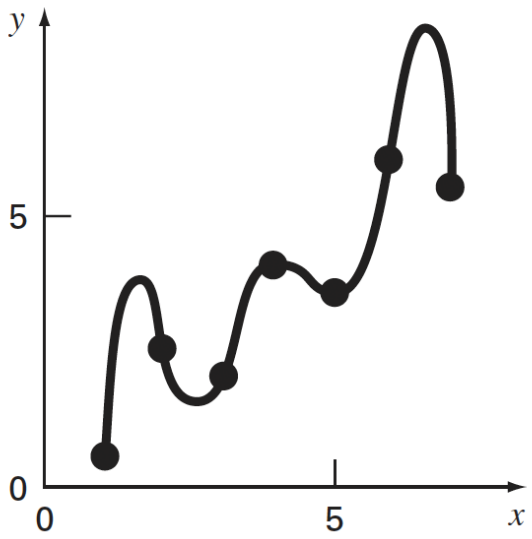

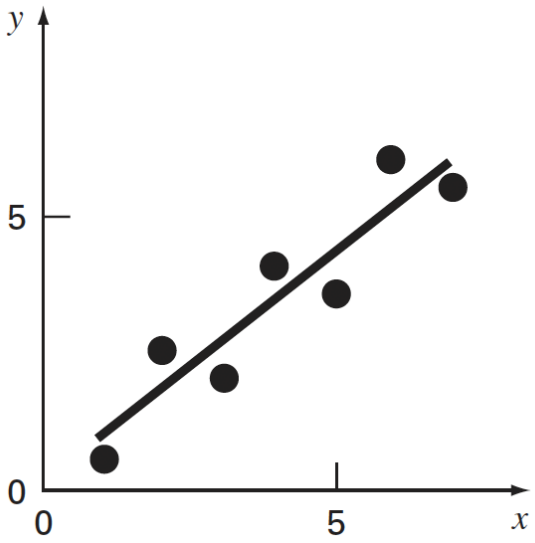

Método dos Mínimos Quadrados

Critério para um Melhor Ajuste

- Um critério que mede a qualidade do ajuste é necessário por duas razões:
  1. Pode ser usado para comparar diferentes funções usadas no ajuste do mesmo conjunto de pontos.
  2. Pode ser usado para determinar os coeficientes da função que leve ao melhor ajuste.
- O ajuste entre um conjunto de dados e uma função aproximada é determinado com o cálculo do erro ou resíduo, que é a diferença entre cada ponto pertencente ao conjunto de dados e o valor da função aproximada.
- Os resíduos são usados para calcular o erro total em todos os pontos.

Método dos Mínimos Quadrados

- O resíduo r_i em um ponto (x_i, y_i) é a diferença entre o valor y_i do ponto medido e do valor da função $f(x_i)$ usada para aproximar o conjunto de dados.
- Um critério que mede quão bem a função aproximada é capaz de representar os dados fornecidos pode ser obtido com o cálculo do erro total E em termos dos resíduos.
- Uma possibilidade é fazer com que o erro global E seja igual à soma do valor absoluto dos resíduos

$$E = \sum_{i=1}^{n} [y_i - f(x_i)]^2$$

Método dos Mínimos Quadrados

- Com essa definição, o erro global é sempre um número positivo (resíduos positivos e negativos não se cancelam).
- Além disso, maiores resíduos têm um efeito relativamente maior (peso) no erro total.

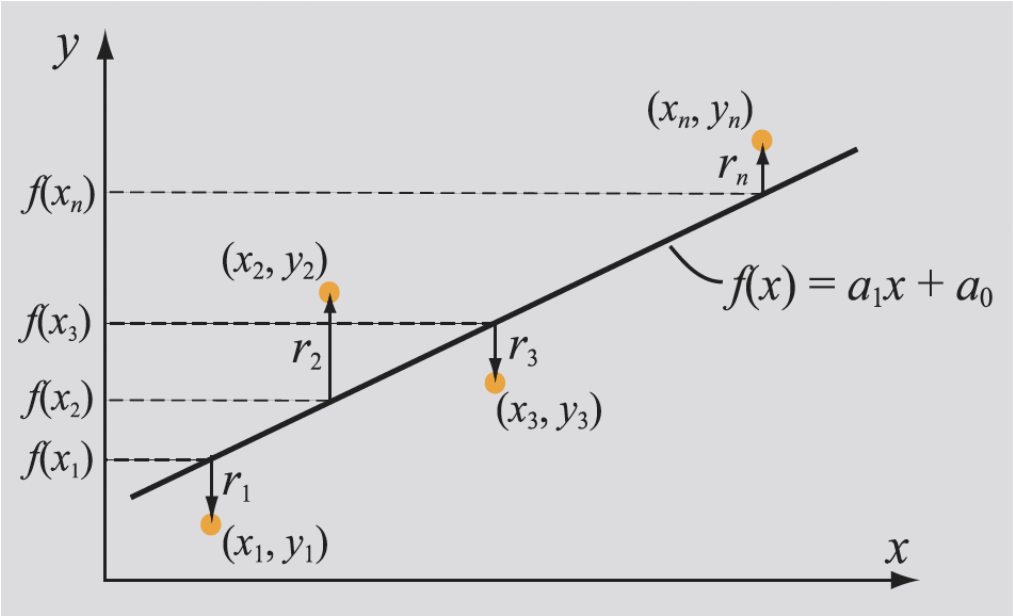

Regressão Linear por Mínimos Quadrados

- A regressão linear por mínimos quadrados é um procedimento no qual os coeficientes a_1 e a_0 da função linear $y = a_1x + a_0$ são determinados de tal forma que essa função leve ao melhor ajuste de um determinado conjunto de pontos.
- Para um dado conjunto de n pontos (x_i, y_i), o erro global é calculado por

$$E = \sum_{i=1}^{n} [y_i - (a_1x_i + a_0)]^2$$

- Como todos os valores x_i e y_i são conhecidos, E é uma função não-linear de duas variáveis, a_1 e a_0.
- A função E tem um mínimo nos valores de a_1 e a_0 nos quais as derivadas parciais de E em relação a cada variável são iguais a zero.

Regressão Linear por Mínimos Quadrados

Calculando as derivadas parciais e as igualando a zero, temos

$$\frac{\partial E}{\partial a_0} = -2\sum_{i=1}^{n}(y_i - a_1 x_i - a_0) = 0 \tag{5.7}$$

$$\frac{\partial E}{\partial a_1} = -2\sum_{i=1}^{n}(y_i - a_1 x_i - a_0)x_i = 0 \tag{5.8}$$

As Eqs. (5.7) e (5.8) formam um sistema de duas equações lineares com incógnitas a_1 e a_0, e podem ser escritas na forma:

$$na_0 + \left(\sum_{i=1}^{n} x_i\right)a_1 = \sum_{i=1}^{n} y_i \tag{5.9}$$

$$\left(\sum_{i=1}^{n} x_i\right)a_0 + \left(\sum_{i=1}^{n} x_i^2\right)a_1 = \sum_{i=1}^{n} x_i y_i \tag{5.10}$$

Regressão Linear por Mínimos Quadrados

Essas são as chamadas equações normais. Elas podem ser resolvidas simultaneamente

$$a_1 = \frac{n\Sigma x_i y_i - \Sigma x_i \Sigma y_i}{n\Sigma x_i^2 - (\Sigma x_i)^2} \tag{17.6}$$

Esse resultado pode, então, ser usado junto com a Equação (17.4) para determinar

$$a_0 = \bar{y} - a_1\bar{x} \tag{17.7}$$

onde $\bar{y}$ e $\bar{x}$ são as médias de y e x, respectivamente.

Exemplo: Ajuste uma reta ao conjunto de pontos dados

								$\sum$
x	1	2	3	4	5	6	7	28
y	0,5	2,5	2,0	4,0	3,5	6,0	5,5	24
$x \cdot y$	0,5	5,0	6,0	16,0	17,5	36,0	38,5	119,5

Regressão Linear por Mínimos Quadrados

Solução. As seguintes quantidades podem ser calculadas:

$$n = 7 \qquad \sum x_i y_i = 119{,}5 \qquad \sum x_i^2 = 140$$

$$\sum x_i = 28 \qquad \bar{x} = \frac{28}{7} = 4$$

$$\sum y_i = 24 \qquad \bar{y} = \frac{24}{7} = 3{,}428571$$

Usando as Equações (17.6) e (17.7),

$$a_1 = \frac{7(119{,}5) - 28(24)}{7(140) - (28)^2} = 0{,}8392857$$

$$a_0 = 3{,}428571 - 0{,}8392857(4) = 0{,}07142857$$

Portanto, o ajuste por mínimos quadrados é

$$y = 0{,}07142857 + 0{,}8392857x$$

Regressão Linear por Mínimos Quadrados

Para estimar o quanto a função de aproximação $\varphi(x_k)$[1] está bem ajustada ao conjunto de pontos, devemos calcular o **coeficiente de determinação** R^2 dado por

$$R^2 = \frac{\sum(\varphi(x_k) - \bar{y})^2}{\sum(y_k - \bar{y})^2}$$

Uma formulação alternativa para R que é mais conveniente para implementação computacional é

$$r = \frac{n\Sigma x_i y_i - (\Sigma x_i)(\Sigma y_i)}{\sqrt{n\Sigma x_i^2 - (\Sigma x_i)^2}\sqrt{n\Sigma y_i^2 - (\Sigma y_i)^2}}$$

[1] No Exemplo anterior, temos que $\varphi(x_k) = y(x_k)$

Regressão Linear por Mínimos Quadrados

No exemplo anterior, temos
$\varphi(1) = 0,910714$, $\varphi(2) = 1,75$, $\varphi(3) = 2,58929$, $\varphi(4) = 3,42857$, $\varphi(5) = 4,26785$, $\varphi(6) = 5,10714$ e $\varphi(7) = 5,94642$.
Aplicando na fórmula temos

$$\begin{aligned} R^2 &= \frac{(0,910714 - 3,428571)^2 + \ldots + (5,94642 - 3,428571)^2}{(0,5 - 3,428571)^2 + \ldots + (5,5 - 3,428571)^2} \\ &= \frac{19,7232}{22,7143} = 0,868318. \end{aligned}$$

Note que $R^2 \in [0,1]$ e quanto mais próximo de 1 for o valor de R^2, mais ajustada está a curva ao conjunto de pontos.

Linearização de Funções Não-lineares

- A regressão linear fornece uma técnica poderosa para ajustar a melhor reta ao conjunto de dados.
- Entretanto, ela é baseada no fato de que a relação entre as variáveis dependentes e independentes é linear.
- Esse não é sempre o caso, e o primeiro passo em qualquer análise de regressão, deve ser traçar e inspecionar visualmente os dados para verificar se um modelo linear se aplica.

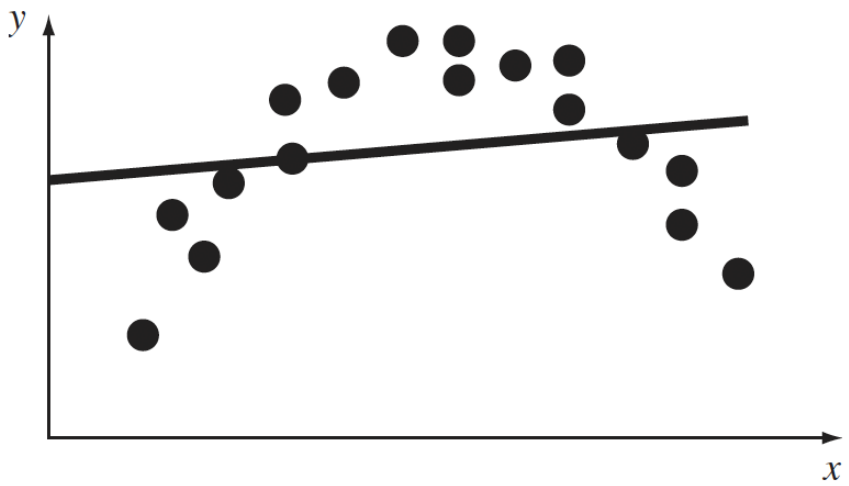

Linearização de Funções Não-lineares

- **Funções Logarítmicas** na forma

$$y = m \cdot ln(x) + b$$

Essa equação é linear com $ln(y)$ em termos de x. A equação está na forma $Y = a_1 X + a_0$, onde $X = ln(x)$.

- **Função Exponencial** na forma

$$y = be^{mx}$$

pode ser linearizada calculando o logaritmo natural em ambos os lados da igualdade por

$$ln(y) = ln\left(be^{mx}\right) = mx + ln(b)$$

Essa equação é linear com $ln(y)$ em termos de x. A equação está na forma $Y = a_1 X + a_0$, onde $Y = ln(y)$, $a_1 = m$, $X = x$ e $a_0 = ln(b)$.

Linearização de Funções Não-lineares

- **Função de Potência** na forma

$$y = bx^m$$

pode ser linearizada calculando o logaritmo natural em ambos os lados da igualdade por

$$ln(y) = ln\left(bx^m\right) = m \cdot ln(x) + ln(b)$$

Essa equação é linear com $ln(y)$ em termos de $ln(x)$. A equação está na forma $Y = a_1X + a_0$, onde $Y = ln(y)$, $a_1 = m$, $X = ln(x)$ e $a_0 = ln(b)$.

- Podemos linearizar funções quociente da seguinte forma:

Linearização de Funções Não-lineares

$y = \dfrac{1}{mx+b}$	$\dfrac{1}{y} = mx + b$	$Y = \dfrac{1}{y}, \quad X = x$ $a_1 = m, \quad a_0 = b$
$y = \dfrac{mx}{b+x}$	$\dfrac{1}{y} = \dfrac{b}{m}\dfrac{1}{x} + \dfrac{1}{m}$	$Y = \dfrac{1}{y}, \quad X = \dfrac{1}{x}$ $a_1 = \dfrac{b}{m}, \quad a_0 = \dfrac{1}{m}$

Considerações com relação à escolha da função não-linear adequada para o ajuste de uma curva são as seguintes:

- Funções exponenciais não podem passar pela origem.
- Funções exponenciais apenas são definidas para valores de y positivos ou negativos.
- Funções logarítmicas não existem para $x \leqslant 0$.
- Função potência, y = 0 quando x = 0.

Linearização de Funções Não-lineares

OBS: Lembre-se que os valores a_0 e a_1 são calculados nos pontos linearizados, assim os valores de m e b devem ser convertidos para a função original.

Exemplo: Ajuste o conjunto de pontos e verifique qual linearização tem melhor ajuste.

x	2	4	6	8	10	12	14	16	$\cdots$
y	9,7	8,1	6,6	5,1	4,4	3,7	2,8	2,4	$\cdots$

x	$\cdots$	18	20	22	24	26	28	30
y	$\cdots$	2,0	1,6	1,4	1,1	0,85	0,69	0,6

Regressão Polinomial

- A regressão polinomial é um procedimento usado na determinação dos coeficientes de um polinômio de grau n, de forma que esse polinômio produza o melhor ajuste de um determinado conjunto de dados.
- Um polinômio de segundo grau tem a forma

$$f(x) = a_0 + a_1 x + a_2 x^2$$

- A soma dos quadrados dos resíduos é

$$E = \sum_{i=1}^{n} [y_i - (a_0 + a_1 x_i + a_2 x_i^2)]^2$$

Regressão Polinomial

Calculando as derivadas parciais em relação a a_0, a_1 e a_2 e igualando os resultados a zero, obtém-se

$$\frac{\partial E}{\partial a_0} = -2 \sum_{i=1}^{n} (y_i - a_2 x_i^2 - a_1 x_i - a_0) = 0$$

$$\frac{\partial E}{\partial a_1} = -2 \sum_{i=1}^{n} (y_i - a_2 x_i^2 - a_1 x_i - a_0) x_i = 0$$

$$\frac{\partial E}{\partial a_2} = -2 \sum_{i=1}^{n} (y_i - a_2 x_i^2 - a_1 x_i - a_0) x_i^2 = 0$$

As equações acima formam um sistema de três equações lineares em função das incógnitas a_0, a_1 e a_2, que pode ser rescrito na forma

Regressão Polinomial

$$
\begin{aligned}
n a_0 + \left(\sum^{n} x_i \right) a_1 + \left(\sum^{n} x_i^2 \right) a_2 &= \sum^{n} y_i \\
\left(\sum_{i=1}^{n} x_i \right) a_0 + \left(\sum_{i=1}^{n} x_i^2 \right) a_1 + \left(\sum_{i=1}^{n} x_i^3 \right) a_2 &= \sum_{i=1}^{n} x_i y_i \\
\left(\sum_{i=1}^{n} x_i^2 \right) a_0 + \left(\sum_{i=1}^{n} x_i^3 \right) a_1 + \left(\sum_{i=1}^{n} x_i^4 \right) a_2 &= \sum_{i=1}^{n} x_i^2 y_i
\end{aligned}
$$

- A solução do sistema de equações fornece os valores dos coeficientes a_0, a_1 e a_2 do polinômio $f(x) = a_0 + a_1 x + a_2 x^2$ que melhor se ajusta aos n pontos (x_i, y_i).
- Os coeficientes de polinômios de ordem superior são deduzidos da mesma forma. Para um polinômio de ordem m, as equações são estendidas para formar um conjunto de $m+1$ equações lineares em função dos $m+1$ coeficientes.

Regressão Polinomial

Exemplo: Ajuste um polinômio do segundo grau aos dados da tabela

x	0	1	2	3	4	5
y	2,1	7,7	13,6	27,2	40,9	61,1

Solução:

$$m = 2 \qquad \sum x_i = 15 \qquad \sum x_i^4 = 979$$

$$n = 6 \qquad \sum y_i = 152{,}6 \qquad \sum x_i y_i = 585{,}6$$

$$\overline{x} = 2{,}5 \qquad \sum x_i^2 = 55 \qquad \sum x_i^2 y_i = 2488{,}8$$

$$\overline{y} = 25{,}433 \qquad \sum x_i^3 = 225$$

Regressão Polinomial

Portanto, as equações lineares simultâneas são

$$\begin{bmatrix} 6 & 15 & 55 \\ 15 & 55 & 225 \\ 55 & 225 & 979 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} 152{,}6 \\ 585{,}6 \\ 2488{,}8 \end{Bmatrix}$$

Resolvendo essas equações por uma técnica como a eliminação de Gauss, obtêm-se $a_0 = 2{,}47857$, $a_1 = 2{,}35929$ e $a_2 = 1{,}86071$. Portanto, a equação quadrática por mínimos quadrados é

$$y = 2{,}47857 + 2{,}35929x + 1{,}86071x^2$$

O coeficiente de determinação é

$$R^2 = 0,998509$$

Regressão Linear Múltipla

- Uma extensão útil da regressão linear é o caso no qual y é uma função linear de duas ou mais variáveis independentes.
- Por exemplo, y poderia ser uma função linear de x_1 e x_2, do tipo

$$y = a_0 + a_1 x_1 + a_2 x_2$$

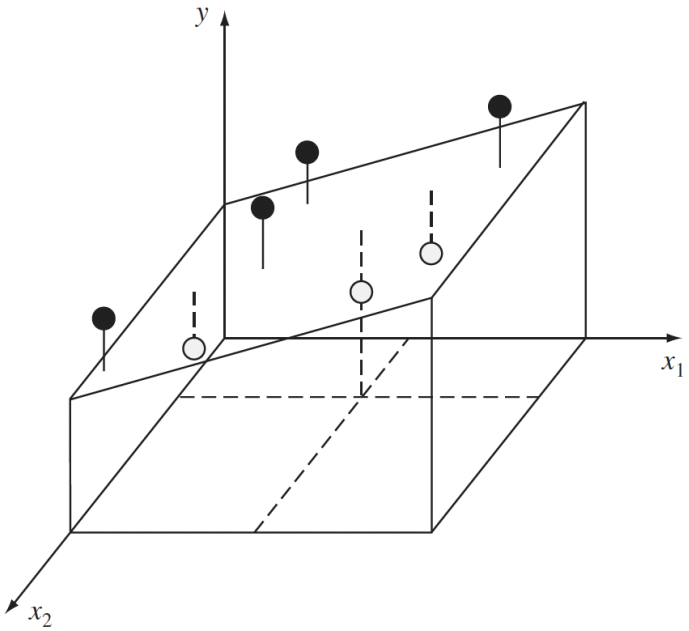

Regressão Linear Múltipla

Os "melhores" valores dos coeficientes são determinados escrevendo a soma dos quadrados dos resíduos

$$E = \sum_{i=1}^{n} [y_i - (a_0 + a_1 x_{1i} + a_2 x_{2i})]^2$$

Derivando com relação a cada um dos coeficientes desconhecidos, temos

$$\begin{aligned}
\frac{\partial E}{\partial a_0} &= -2 \sum_{i=1}^{n} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i}) \\
\frac{\partial E}{\partial a_1} &= -2 \sum_{i=1}^{n} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i}) \cdot x_{1i} \\
\frac{\partial E}{\partial a_2} &= -2 \sum_{i=1}^{n} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i}) \cdot x_{2i}
\end{aligned}$$

Regressão Linear Múltipla

Os coeficientes fornecendo a soma mínima dos quadrados dos resíduos são obtidos igualando as derivadas parciais a zero e expressando o resultado na forma matricial como

$$\begin{bmatrix} n & \Sigma x_{1i} & \Sigma x_{2i} \\ \Sigma x_{1i} & \Sigma x_{1i}^2 & \Sigma x_{1i} x_{2i} \\ \Sigma x_{2i} & \Sigma x_{1i} x_{2i} & \Sigma x_{2i}^2 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} \Sigma y_i \\ \Sigma x_{1i} y_i \\ \Sigma x_{2i} y_i \end{Bmatrix}$$

Exemplo: Use regressão linear múltipla para ajustar os dados calculados a partir da equação $y = 5 + 4x_1 - 3x_2$.

x_1	0	2	2,5	1	4	7
x_2	0	1	2	3	6	2
y	5	10	9	0	3	27

Regressão Linear Múltipla

Solução: Após calcular as somatórias, o resultado é

$$\begin{bmatrix} 6 & 16{,}5 & 14 \\ 16{,}5 & 76{,}25 & 48 \\ 14 & 48 & 54 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} 54 \\ 243{,}5 \\ 100 \end{Bmatrix}$$

que pode ser resolvida usando-se um método como a eliminação de Gauss, obtendo-se

$$a_0 = 5, \;\; a_1 = 4 \;\; e \;\; a_2 = -3$$

Assim,

$$y = 5 + 4x_1 - 3x_2$$

Integração Numérica

- A fórmula geral de uma integral definida de uma função $f(x)$ num intervalo $[a, b]$ é

$$I = \int_a^b f(x)dx$$

- A integração numérica é necessária quando a integração analítica é difícil ou impossível, e quando o integrando é fornecido como um conjunto discreto de pontos.

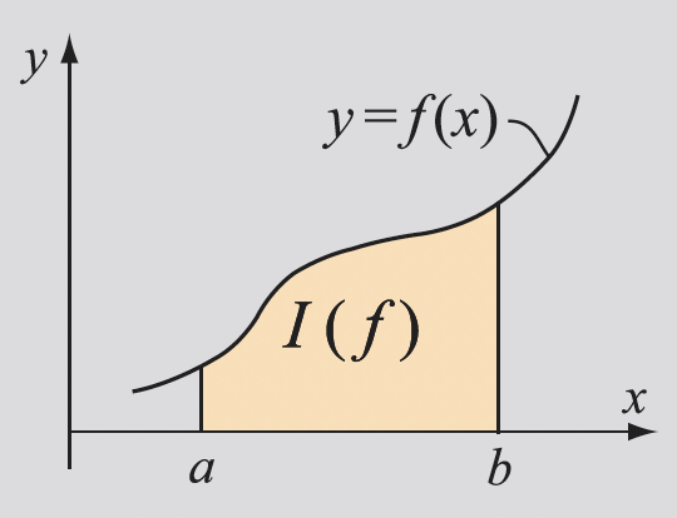

Fórmulas de Integração de Newton-Cotes

- As fórmulas de Newton-Cotes são baseadas na estratégia de substituir uma função complicada ou dados tabelados, por uma função aproximadora simples que seja fácil de integrar

$$I = \int_a^b f(x)dx \approx \int_a^b P_n(x)dx$$

em que $P_n(x)$ é um polinômio na forma

$$P_n(x) = a_0 + a_1 x + a_2 x^2 + \ldots + a_n x^n$$

- A integral também pode ser aproximada, usando uma série de polinômios aplicados por partes à função ou dados em segmentos de comprimento constante.

Fórmulas de Integração de Newton-Cotes

- As formas fechadas são aquelas nas quais os dados nos extremos inicial e final de integração são conhecidos.
- As fórmulas abertas têm extremos de integração que se estendem além do intervalo dos dados.

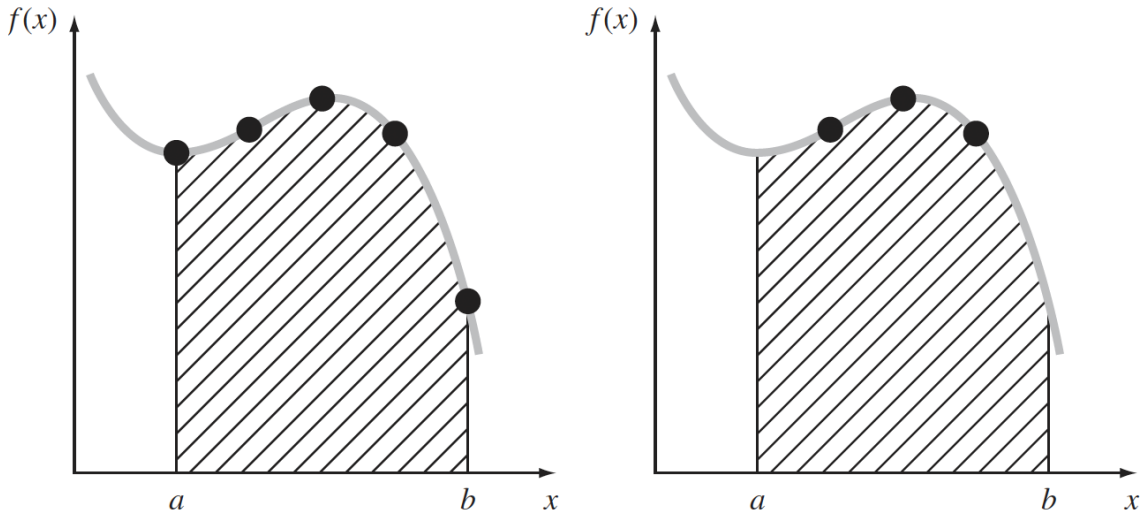

Regra do Trapézio

- A regra do trapézio é a primeira fórmula de integração fechada de Newton-Cotes e usa um polinômio de primeiro grau

$$I = \int_a^b f(x)dx \approx \int_a^b P_1(x)dx$$

- Usando o polinômio interpolador de Newton entre os pontos $x = a$ e $x = b$, temos

$$P_1(x) = f(a) + \frac{f(b) - f(a)}{b - a} \cdot (x - a)$$

- A área sob essa reta é uma estimativa da integral de $f(x)$ entre os extremos a e b, dado por

$$I = \int_a^b \left[f(a) + \frac{f(b) - f(a)}{b - a} \cdot (x - a) \right] dx$$

Regra do Trapézio

- O resultado da integração é

$$I = \frac{b-a}{2} \cdot [f(a) + f(b)]$$

que é chamada **regra do trapézio**.

- A estimativa da integral pode ser representada por

$$I \approx \text{largura} \times \text{altura média}.$$

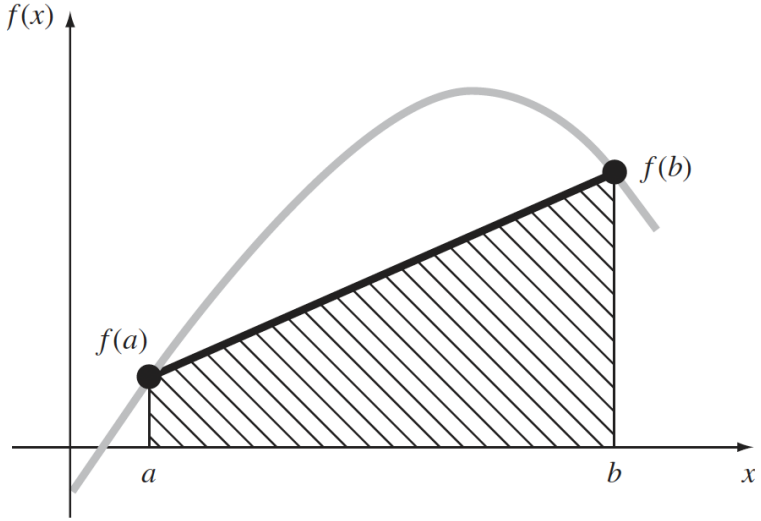

Erro na Regra do Trapézio

Uma estimativa para o erro de truncamento local de uma única aplicação da regra do trapézio é

$$E_t = -\frac{1}{12} f''(\xi)(b-a)^3$$

em que ξ está em algum ponto do intervalo (a, b).

Exemplo: Use a integração numerica para a função

$$f(x) = 0,2 + 25x - 200x^2 + 675x^3 - 900x^4 + 400x^5$$

no intervalo [0, 0.8]. O valor exato da integral é 1,640533.

Erro na Regra do Trapézio

A integração numérica é $I = \dfrac{0,8}{2} \cdot [0,2 + 0,232] = 0,1728$ e o erro

$$E_t = -\frac{1}{12}\left(\frac{\int_0^{0.8} f''(x)}{0.8 - 0}dx\right)(0,8)^3 = -\frac{1}{12}(-60)\cdot(0,8)^3 = 2,56$$

Existe uma discrepância porque a média da segunda derivada não é uma aproximação acurada de $f''(\xi)$. A razão para esse erro grande é evidente na descrição gráfica.

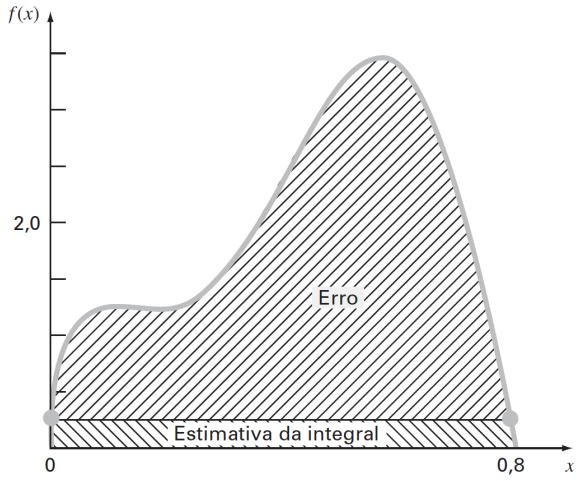

Regra do Trapézio Composta

- Uma maneira de melhorar a acurácia da regra do trapézio é dividir o intervalo de integração de a até b em diversos segmentos e aplicar o método a cada segmento.
- As áreas correspondentes aos segmentos individuais podem ser somadas para fornecer a integral para o intervalo inteiro.
- Considere $n+1$ pontos igualmente espaçados $(x_0, x_1, \ldots, x_n)$. Assim, existem n segmentos de largura

$$h = \frac{b-a}{n}$$

Se a e b forem designados por x_0 e x_n, respectivamente, a integral total pode ser representada como

$$I = \int_{x_0}^{x_1} f(x)dx + \int_{x_1}^{x_2} f(x)dx + \ldots + \int_{x_{n-1}}^{x_n} f(x)dx$$

Regra do Trapézio Composta

Substituindo cada integral pela regra do trapézio, temos

$$I = h \cdot \frac{f(x_0) + f(x_1)}{2} + h \cdot \frac{f(x_1) + f(x_2)}{2} + \ldots + h \cdot \frac{f(x_{n-1}) + f(x_n)}{2}$$

Portanto,

$$I = \frac{h}{2}\left[f(x_0) + 2 \cdot \sum_{i=1}^{n-1} f(x_i) + f(x_n)\right]$$

Um erro para a aplicação múltipla da regra do trapézio pode ser obtido pela soma dos erros individuais em cada segmento

$$E_t = -\frac{(b-a)^3}{12n^3} \sum_{i=1}^{n} f''(\xi)$$

Regra 1/3 de Simpson

- Uma forma de obter uma estimativa mais acurada de uma integral é usar polinômios de grau mais alto para ligar os pontos.
- Se existir um ponto extra no ponto médio entre $f(a)$ e $f(b)$, os três pontos podem ser ligados por uma parábola.
- A regra 1/3 de Simpson usa um polinômio interpolador de segundo grau

$$I = \int_a^b f(x)dx \approx \int_a^b P_2(x)dx$$

- Se a e b forem designados por x_0 e x_2 e se $P_2(x)$ for um polinômio de Lagrange de segundo grau, a integral se torna

Regra 1/3 de Simpson

$$I = \int_{x_0}^{x_2} \left[\frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)} f(x_0) + \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)} f(x_1) + \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)} f(x_2) \right] dx$$

Depois da integração e de manipulações algébricas, obtémos a seguinte fórmula

$$I \approx \frac{h}{3}\left[f(x_0) + 4f(x_1) + f(x_2)\right]$$

O erro de aproximação é dado por

$$E_t = -\frac{h^5}{90} f^{(4)}(\xi)$$

Regra 1/3 de Simpson Composto

Do mesmo modo da regra do trapézio, a regra 1/3 de Simpson pode ser melhorada dividindo o intervalo de integração em diversos segmentos de mesmo comprimento $h = \dfrac{b-a}{n}$.

A integral total pode ser representada como

$$I = \int_{x_0}^{x_2} f(x)\,dx + \int_{x_2}^{x_4} f(x)\,dx + \cdots + \int_{x_{n-2}}^{x_n} f(x)\,dx$$

Substituindo cada integral individual pela regra 1/3 de Simpson, obtemos

$$I \cong 2h\frac{f(x_0) + 4f(x_1) + f(x_2)}{6} + 2h\frac{f(x_2) + 4f(x_3) + f(x_4)}{6}$$

$$+ \cdots + 2h\frac{f(x_{n-2}) + 4f(x_{n-1}) + f(x_n)}{6}$$

Regra 1/3 de Simpson Composto

$$I = \frac{h}{3}\left[f(x_1) + 4\sum_{i=2,4,\ldots}^{n} f(x_i) + 2\sum_{j=3,5,\ldots}^{n-1} f(x_j) + f(x_{n+1})\right]$$

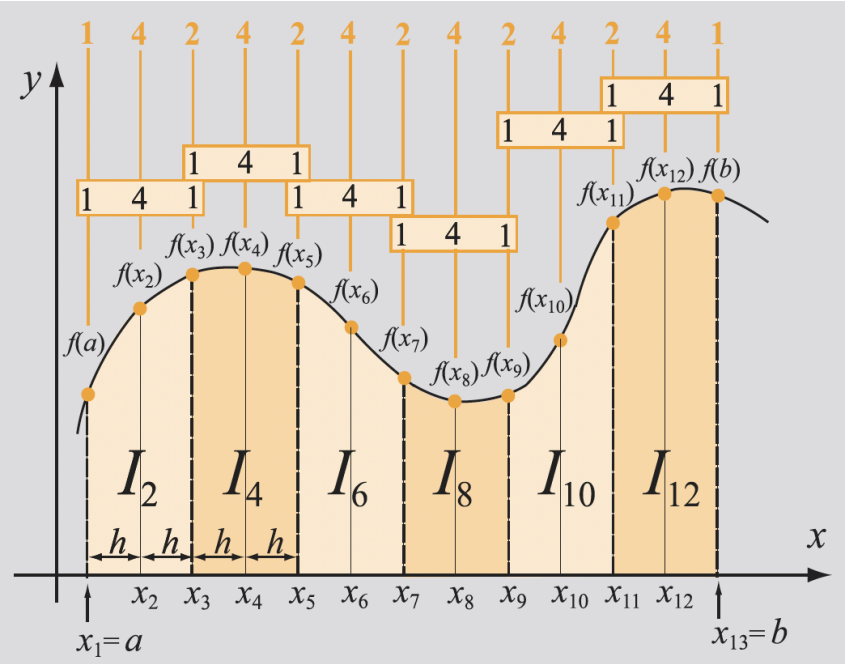

Regra 1/3 de Simpson Composto

- O erro de aproximação é dado por

$$E_t = -\frac{(b-a)^5}{180n^4} f^{(4)}(\xi)$$

  em que $f^{(4)}(\xi)$ é o valor médio da quarta derivada no intervalo.
- Os subintervalos devem ser igualmente espaçados.
- O número de subintervalos no domínio $[a, b]$ deve ser divisível por 2.

Regra 3/8 de Simpson

- Se existir dois pontos igualmente espaçados entre $f(a)$ e $f(b)$, os quatro pontos podem ser ligados por um polinômio de 3° grau. Esta fórmula é conhecida como regra 3/8 de Simpson e dada por

$$I = \frac{3h}{8}\left[f(x_0) + 3f(x_1) + 3f(x_2) + f(x_3)\right]$$

- O erro de aproximação é dado por

$$E_t = -\frac{3h^5}{80} f^{(4)}(\xi)$$

Regra 3/8 de Simpson Composto

$$I=\frac{3h}{8}\left[f(x_1)+3\sum_{i=2,5,8,\ldots}^{n-1}[f(x_i)+f(x_{i+1})]+2\sum_{j=4,7,10,\ldots}^{n-2}f(x_j)+f(x_{n+1})\right]$$

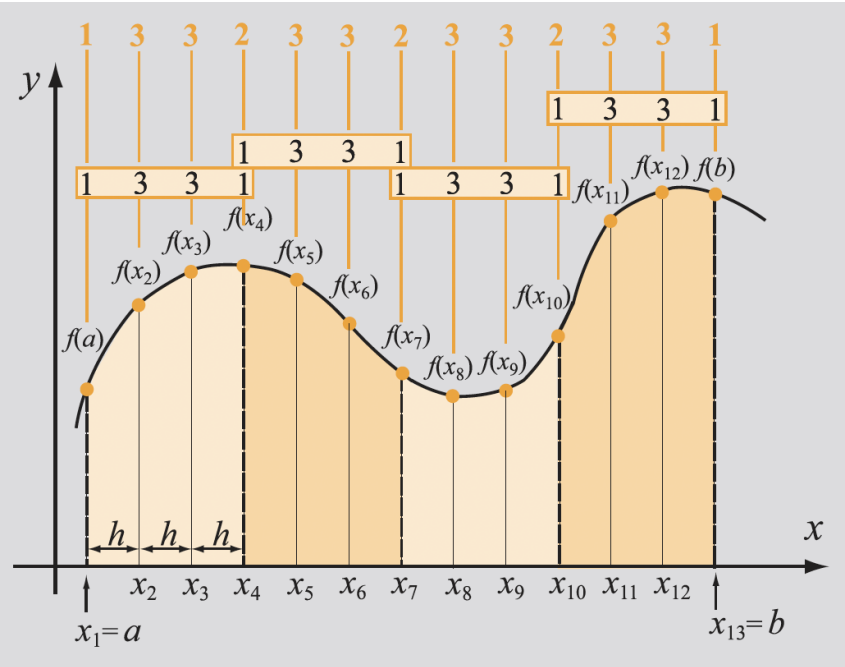

Regra 3/8 de Simpson Composto

- O erro de aproximação é dado por

$$E_t = -\frac{(b-a)^5}{6.480} f^{(4)}(\xi)$$

  em que $f^{(4)}(\xi)$ é o valor médio da quarta derivada no intervalo.
- Os subintervalos devem ser igualmente espaçados.
- O número de subintervalos $[a, b]$ deve ser divisível por 3.

Quadratura de Gauss

- Os pontos de Gauss não são igualmente espaçados e não incluem os pontos extremos do intervalo.
- A localização dos pontos e os pesos correspondentes de $f(x)$ são determinados de forma a minimizar o erro.

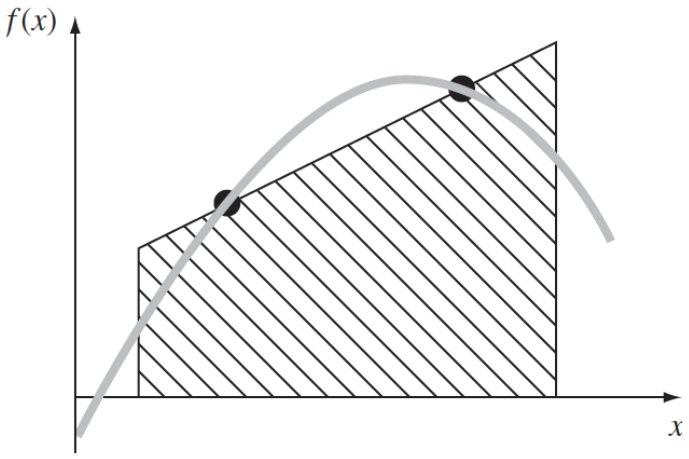

Quadratura de Gauss

- A forma geral da quadratura de Gauss é

$$\int_a^b f(x)dx = \sum_{i=1}^{n} C_i f(x_i)$$

  onde os coeficientes C_i são os pesos e x_i são os pontos de Gauss no intervalo $[a, b]$.
- Para $n = 2$, em contraste com a regra do trapézio que usa extremidades fixas a e b, os argumentos da função x_0 e x_1 não são fixados nas extremidades, mas são incógnitas.
- Assim, temos um total de quatro incógnitas que devem ser calculadas e necessitamos de quatro condições para determiná-las exatamente.

Quadratura de Gauss

No domínio [−1, 1], a forma da quadratura de Gauss é:

$$\int_{-1}^{1} f(x)dx \approx \sum_{i=1}^{n} C_i f(x_i) \tag{7.24}$$

Os coeficientes C_i e a localização dos pontos de Gauss x_i são determinados fazendo com que a Eq. (7.24) seja exata quando $f(x) = 1, x, x^2, x^3$, etc. O número de casos a ser considerado depende do valor de n. Por exemplo, quando $n = 2$:

$$\int_{-1}^{1} f(x)dx \approx C_1 f(x_1) + C_2 f(x_2) \tag{7.25}$$

As quatro constantes C_1, C_2, x_1 e x_2 são determinadas fazendo com que a Eq. (7.25) seja exata quando aplicada aos quatro casos a seguir:

Caso 1: $f(x) = 1$ $\quad \int_{-1}^{1} (1)dx = 2 = C_1 + C_2$

Caso 2: $f(x) = x$ $\quad \int_{-1}^{1} xdx = 0 = C_1x_1 + C_2x_2$

Caso 3: $f(x) = x^2$ $\quad \int_{-1}^{1} x^2dx = \frac{2}{3} = C_1x_1^2 + C_2x_2^2$

Caso 4: $f(x) = x^3$ $\quad \int_{-1}^{1} x^3dx = 0 = C_1x_1^3 + C_2x_2^3$

Quadratura de Gauss

Os quatro casos fornecem um conjunto de quatro equações e quatro incógnitas. As equações são não-lineares, o que significa que podem existir múltiplas soluções. Uma solução particular pode ser obtida impondo-se um requisito adicional. Aqui, esse requisito é escolhido de tal forma que os pontos x_1 e x_2 estejam localizados simetricamente em relação a $x = 0$ ($x_1 = -x_2$). Da segunda equação, isso implica que $C_1 = C_2$. Com esses requisitos, a solução da equação resulta em:

$$C_1 = 1, \quad C_2 = 1, \; x_1 = -\frac{1}{\sqrt{3}} = -0{,}57735027, \; x_2 = \frac{1}{\sqrt{3}} = 0{,}57735027$$

A substituição das constantes de volta na Eq. (7.25) fornece, para $n = 2$:

$$\int_{-1}^{1} f(x)dx \approx f\left(-\frac{1}{\sqrt{3}}\right) + f\left(\frac{1}{\sqrt{3}}\right) \tag{7.26}$$

Para $f(x) = x^2$, temos

$$\int_{-1}^{1} x^2 dx = \frac{2}{3} = 1 \cdot \left(-\frac{1}{\sqrt{3}}\right)^2 + 1 \cdot \left(\frac{1}{\sqrt{3}}\right)^2$$

Quadratura de Gauss

Para $f(x) = \cos(x)dx$, temos $\int_{-1}^{1} \cos(x)dx = 1,68294197$ e

$$\cos\left(-\frac{1}{\sqrt{3}}\right) + \cos\left(\frac{1}{\sqrt{3}}\right) = 1,67582366$$

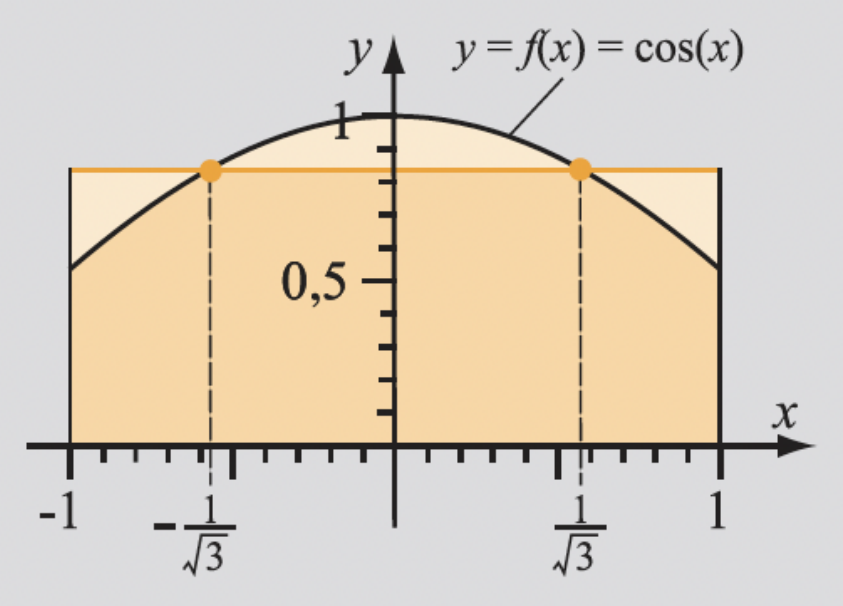

Quadratura de Gauss

n (Número de pontos)	Coeficientes C_i (pesos)	Pontos de Gauss x_i
2	$C_1 = 1$ $C_2 = 1$	$x_1 = -0{,}57735027$ $x_2 = 0{,}57735027$
3	$C_1 = 0{,}5555556$ $C_2 = 0{,}8888889$ $C_3 = 0{,}5555556$	$x_1 = -0{,}77459667$ $x_2 = 0$ $x_3 = 0{,}77459667$
4	$C_1 = 0{,}3478548$ $C_2 = 0{,}6521452$ $C_3 = 0{,}6521452$ $C_4 = 0{,}3478548$	$x_1 = -0{,}86113631$ $x_2 = -0\ 33998104$ $x_3 = 0{,}33998104$ $x_4 = 0{,}86113631$
5	$C_1 = 0{,}2369269$ $C_2 = 0{,}4786287$ $C_3 = 0{,}5688889$ $C_4 = 0{,}4786287$ $C_5 = 0{,}2369269$	$x_1 = -0{,}90617985$ $x_2 = -0{,}53846931$ $x_3 = 0$ $x_4 = 0{,}53846931$ $x_5 = 0{,}90617985$
6	$C_1 = 0{,}1713245$ $C_2 = 0{,}3607616$ $C_3 = 0{,}4679139$ $C_4 = 0{,}4679139$ $C_5 = 0{,}3607616$ $C_6 = 0{,}1713245$	$x_1 = -0{,}93246951$ $x_2 = -0{,}66120938$ $x_3 = -0{,}23861919$ $x_4 = 0{,}23861919$ $x_5 = 0{,}66120938$ $x_6 = 0{,}93246951$

Quadratura de Gauss

Integração de $\int_a^b f(x)dx$ com a quadratura de Gauss

Os coeficientes de peso e as coordenadas dos pontos de Gauss fornecidos na Tabela 7-1 são válidos apenas quando o intervalo de integração é $[-1, 1]$. Em geral, contudo, o intervalo pode ser qualquer domínio $[a, b]$. Ainda assim, pode-se usar a quadratura de Gauss com os coeficientes e pontos determinados para $[-1, 1]$ no caso de um domínio genérico. Isso é feito com a transformação da integral $\int_a^b f(x)dx$ em uma integral na forma $\int_{-1}^1 f(t)dt$ por meio da mudança de variáveis:

$$x = \frac{1}{2}[t(b-a) + a + b] \qquad \text{e} \qquad dx = \frac{1}{2}(b-a)dt \tag{7.31}$$

A integração então tem a forma:

$$\int_a^b f(x)dx = \int_{-1}^1 f\left(\frac{(b-a)t + a + b}{2}\right)\frac{(b-a)}{2}dt$$

Quadratura de Gauss

Avalie $\int_0^3 e^{-x^2}dx$ usando a quadratura de Gauss de quarta ordem.

SOLUÇÃO

Passo 1 Como os limites de integração são [0, 3], a integral tem que ser transformada para a forma $\int_{-1}^{1} f(t)dt$. No presente problema, $a = 0$ e $b = 3$. Substituindo esses valores na Eq. (7.31), obtém-se:

$$x = \frac{1}{2}[t(b-a)+a+b] = \frac{1}{2}[t(3-0)+0+3] = \frac{3}{2}(t+1) \quad \text{e} \quad dx = \frac{1}{2}(b-a)dt = \frac{1}{2}(3-0)dt = \frac{3}{2}dt$$

A substituição desses valores na integral fornece:

$$I = \int_0^3 e^{-x^2}dx = \int_{-1}^{1} f(t)dt = \int_{-1}^{1} \frac{3}{2}e^{-\left[\frac{3}{2}(t+1)\right]^2}dt$$

Passo 2 Use a quadratura de Gauss de quarta ordem para avaliar a integral. A partir da Eq. (7.30) e usando a Tabela 7-1:

$$I = \int_{-1}^{1} f(t)dt \approx C_1 f(t_1) + C_2 f(t_2) + C_3 f(t_3) + C_4 f(t_4) = 0{,}3478548 f(-0{,}86113631)$$
$$+ 0{,}6521452 f(-0{,}33998104) + 0{,}6521452 f(0{,}33998104) + 0{,}3478548 f(0{,}86113631)$$

A avaliação de $f(t) = \frac{3}{2}e^{-\left[\frac{3}{2}(t+1)\right]^2}$ fornece:

Quadratura de Gauss

$$I = \left(0{,}3478548\,\frac{3}{2}e^{-\left[\frac{3}{2}((-0{,}86113631)+1)\right]^2} + 0{,}6521452\,\frac{3}{2}e^{-\left[\frac{3}{2}((-0{,}33998104)+1)\right]^2}\right.$$
$$\left. + 0{,}6521452\frac{3}{2}e^{-\left[\frac{3}{2}((0{,}33998104)+1)\right]^2} + 0{,}3478548\frac{3}{2}e^{-\left[\frac{3}{2}((0{,}86113631)+1)\right]^2}\right) = 0{,}8841359$$

O valor exato da integral (quando realizada analiticamente) é 0,8862073. Dessa forma, o erro é pequeno, da ordem de 1%.

Exemplo: Usando a quadratura de Gauss de segunda ordem, calcule a integral da função

$$f(x) = 0,2 + 25x - 200x^2 + 675x^3 - 900x^4 + 400x^5$$

no intervalo [0, 0.8]. O valor exato da integral é 1,6405333333.