Sistemas de Equações Lineares

Prof. Dr. Ivan Mezzomo

PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA - PPGEE/UFERSA

FUNDAMENTOS DE MODELAGEM COMPUTACIONAL

Introdução

A forma geral de um sistema contendo n equações lineares e sua respectiva forma matricial, é dado por

$$\begin{array}{rcl} a_{11}x_1 + a_{12}x_2 + \ldots + a_{1n}x_n & = & b_1 \\ a_{21}x_1 + a_{22}x_2 + \ldots + a_{2n}x_n & = & b_2 \\ \vdots \qquad\qquad \vdots \qquad\qquad \vdots & & \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \ldots + a_{nn}x_n & = & b_n \end{array}$$

$$\begin{bmatrix} a_{11} & a_{12} & \ldots & a_{1n} \\ a_{21} & a_{22} & \ldots & a_{2n} \\ \ldots & \ldots & \ldots & \ldots \\ a_{n1} & a_{n2} & \ldots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \ldots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \ldots \\ b_n \end{bmatrix}$$

Introdução

- Dois tipos de métodos numéricos (direto e iterativo) são usados para resolver sistemas de equações lineares algébricas.
- Nos **métodos diretos**, a solução é obtida com a realização de operações algébricas nas equações.
  - Vantagens: Solução exata (a menos de erros de arredondamento), previsibilidade no número de operações, estabilidade para sistemas bem-condicionados, não requerem chute inicial, eficientes para sistemas de pequeno e médio porte.
  - Desvantagens: Custo computacional para eliminação Gaussiana, problemas com esparsidade, instabilidade numérica para sistemas mal-condicionados, armazenamento de matrizes densas, dificuldade com sistemas muito grandes.
- Quando usar métodos diretos? Sistemas de pequeno e médio porte, matrizes densas, quando a solução exata é necessária, múltiplos sistemas com mesma matriz A.

Introdução

- Nos **métodos iterativos**, uma solução inicial aproximada é assumida e então utilizada em um processo iterativo para que soluções mais precisas sejam obtidas sucessivamente.
  - Vantagens: Eficiência com matrizes esparsas, menor requerimento de memória, auto-correção de erros de arredondamento, parada antecipada com solução aproximada, estabilidade para sistemas muito grandes.
  - Desvantagens: Convergência não garantida, velocidade de convergência variável, dependência do chute inicial, solução aproximada, dificuldade na escolha de parâmetros.
- Quando usar métodos iterativos? Sistemas muito grandes, matrizes esparsas, quando solução aproximada é suficiente, sistemas bem-condicionados e diagonalmente dominantes[1], quando a memória é limitada.

[1] Valor absoluto do elemento da diagonal principal é maior ou igual à soma dos valores absolutos dos outros elementos da mesma linha

Métodos Diretos

- Nos métodos diretos, o sistema de equações inicial é manipulado até se transformar em um sistema equivalente de fácil resolução que tenha, por exemplo, as formas triangular superior, triangular inferior ou diagonal.
- A forma triangular superior é dado por

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ 0 & a_{22} & a_{23} & a_{24} \\ 0 & 0 & a_{33} & a_{34} \\ 0 & 0 & 0 & a_{44} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix}$$

Métodos Diretos

- O sistema nessa forma é resolvido por um procedimento chamado de **substituição regressiva**.
- Começa com a última equação, que é resolvida para x_n.
- O valor de x_n é substituído na equação anterior, que é resolvida para x_{n-1}.
- Para o sistema acima, a solução é dada por

$$x_4 = \frac{b_4}{a_{44}}$$

$$x_3 = \frac{b_3 - a_{34} b_4}{a_{33}}$$

Métodos Diretos

$$x_2 = \frac{b_2 - a_{23}b_3 - a_{24}b_4}{a_{22}}$$

$$x_1 = \frac{b_1 - a_{12}b_2 - a_{13}b_3 - a_{14}b_4}{a_{11}}$$

A fórmula geral para a solução usando a substituição regressiva é

$$x_n = \frac{b_n}{a_{nn}}$$

$$x_i = \frac{b_i - \sum_{j=i+1}^{j=n} a_{ij}b_j}{a_{ii}} \qquad i = n-1, n-2, \ldots 1$$

Métodos Diretos

- A forma triangular inferior é dada por

$$\begin{bmatrix} a_{11} & 0 & 0 & 0 \\ a_{21} & a_{22} & 0 & 0 \\ a_{31} & a_{32} & a_{33} & 0 \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix}$$

- O sistema nessa forma é resolvido por um procedimento chamado de **substituição progressiva**.
- Começa com a primeira equação, que é resolvida para x_1.
- O valor de x_1 é substituído na equação anterior, que é resolvida para x_2.

Métodos Diretos

- Neste caso, a solução é dada por

$$x_1 = \frac{b_1}{a_{11}}, \quad x_2 = \frac{b_2 - a_{21}b_1}{a_{22}}, \quad x_3 = \frac{b_3 - (a_{31}b_1 + a_{32}b_2)}{a_{33}}$$
$$x_4 = \frac{b_4 - (a_{41}b_1 + a_{42}b_2 + a_{43}b_3)}{a_{44}}$$

- A fórmula geral para a solução usando a substituição regressiva é

$$x_1 = \frac{b_1}{a_{11}}$$
$$x_i = \frac{b_i - \sum_{j=i}^{j=i-1} a_{ij}b_j}{a_{ii}} \qquad i = 2, 3, \ldots n$$

- A forma triangular inferior é usada em conjunto com a forma triangular superior no método de decomposição LU.

Método de eliminação de Gauss

- O método de eliminação de Gauss consiste em duas partes.
- A primeira corresponde ao procedimento de eliminação no qual um sistema de equações lineares $A \cdot x = b$ é transformado em um sistema equivalente de equações $A' \cdot x = b'$, onde a matriz de coeficientes A' é triangular superior.
- Na segunda parte, o sistema equivalente é solucionado com o emprego da substituição regressiva.
- Procedimento de eliminação de Gauss: Os coeficientes a_{ii} são chamados de elemento pivô. Para eliminar os termos a_{ij}, com $i > j$, a equação pivô é multiplicada por $m_{ij} = \dfrac{a_{ij}}{a_{ii}}$ e então subtraída da linha pivô.

Método de eliminação de Gauss

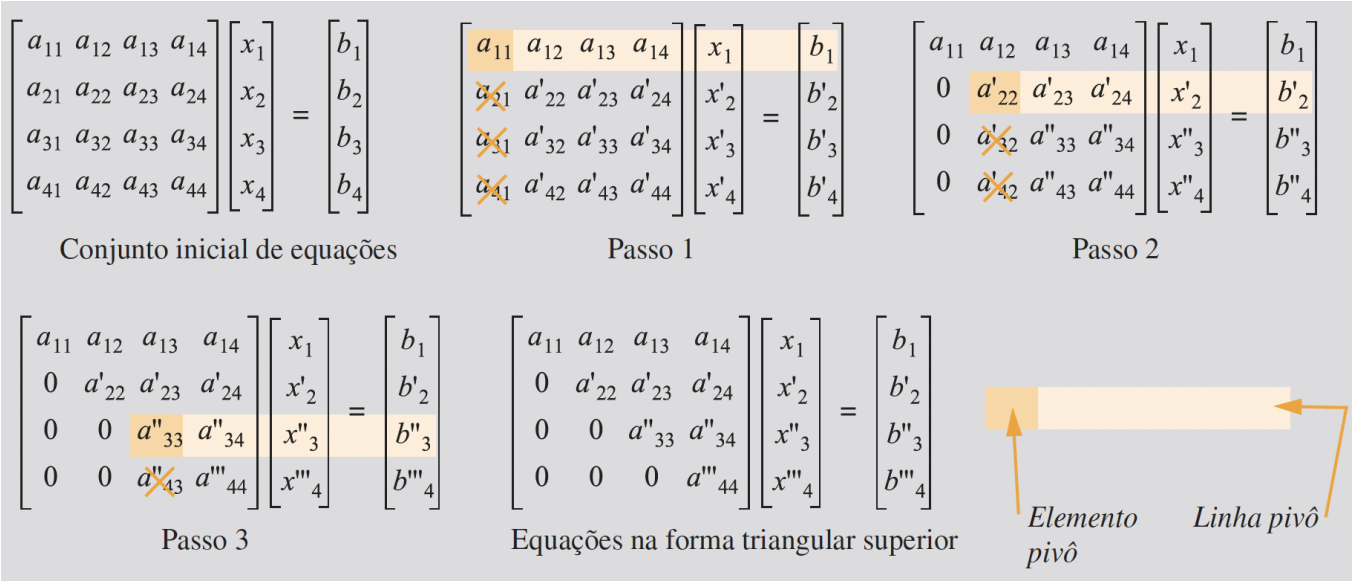

- Se o elemento pivô é zero ou é pequeno em relação aos demais termos na linha pivô, a equação (a linha) deve ser trocada por uma das demais equações (linhas) que possuir um coeficiente pivô mais coerente. Essa troca de linhas é chamada de **pivotamento**.

Decomposição LU

- O procedimento de eliminação de Gauss requer operações matemáticas e um tempo computacional muito mais significativos do que os cálculos realizados na substituição regressiva.
- Se houver a necessidade de resolver sistemas de equações para a mesma matriz A, mas diferentes vetores b, o procedimento de eliminação deve ser feito novamente.
- Uma solução é usar a matriz inversa de A, $x = A^{-1} \cdot b$.
- O cálculo da inversa de uma matriz, contudo, requer muitas operações matemáticas e é computacionalmente ineficiente.
- Um método de solução mais eficiente para este caso é o método de decomposição LU.
- O método de decomposição LU é vantajoso na solução de sistemas que têm as mesmas matrizes de coeficientes A mas diferentes vetores b.

Decomposição LU

- No método de decomposição LU, a matriz de coeficientes A é decomposta (fatorada) em um produto de duas matrizes L e U, i.é.,

$$A = L \cdot U$$

  onde a matriz L é uma matriz triangular inferior e a matriz U é uma matriz triangular superior.
- Com essa decomposição, o sistema de equações tem a forma

$$L \cdot U \cdot x = b$$

- O método de decomposição LU, é definido como

$$U \cdot x = y \text{ e } L \cdot y = b$$

Decomposição LU usando a eliminação de Gauss

- Quando o procedimento de eliminação de Gauss é aplicado em uma matriz A, os elementos das matrizes L e U já são calculados automaticamente.
- A matriz U é a matriz de coeficientes A obtida ao final do procedimento.
- Os elementos diagonais de L são todos iguais a 1 e os elementos abaixo da diagonal são os multiplicadores m_{ij}.

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ m_{21} & 1 & 0 & 0 \\ m_{31} & m_{32} & 1 & 0 \\ m_{41} & m_{42} & m_{43} & 1 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ 0 & a'_{22} & a'_{23} & a'_{24} \\ 0 & 0 & a''_{33} & a''_{34} \\ 0 & 0 & 0 & a'''_{44} \end{bmatrix}$$

Decomposição LU usando a eliminação de Gauss

$$[A] = \begin{bmatrix} 3 & -0,1 & -0,2 \\ 0,1 & 7 & -0,3 \\ 0,3 & -0,2 & 10 \end{bmatrix}$$

Após a eliminação progressiva, foi obtida a seguinte matriz triangular superior:

$$[U] = \begin{bmatrix} 3 & -0,1 & -0,2 \\ 0 & 7,00333 & -0,293333 \\ 0 & 0 & 10,0120 \end{bmatrix}$$

Os fatores empregados para obter a matriz triangular superior podem ser reunidos em uma matriz triangular inferior. Os elementos a_{21} e a_{31} foram eliminados usando-se os fatores

$$f_{21} = \frac{0,1}{3} = 0,03333333 \qquad f_{31} = \frac{0,3}{3} = 0,1000000$$

e o elemento a'_{32} foi eliminado usando-se o fator

$$f_{32} = \frac{-0,19}{7,00333} = -0,0271300$$

Assim, a matriz triangular inferior é

$$[L] = \begin{bmatrix} 1 & 0 & 0 \\ 0,0333333 & 1 & 0 \\ 0,100000 & -0,0271300 & 1 \end{bmatrix}$$

Decomposição LU usando o método de Crout

- Os elementos diagonais da matriz U são todos iguais a 1.
- Os elementos de ambas as matrizes podem ser determinados com o uso de fórmulas de fácil programação.
- No método de Crout, a decomposição LU tem a forma:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} = \begin{bmatrix} L_{11} & 0 & 0 & 0 \\ L_{21} & L_{22} & 0 & 0 \\ L_{31} & L_{32} & L_{33} & 0 \\ L_{41} & L_{42} & L_{43} & L_{44} \end{bmatrix} \begin{bmatrix} 1 & U_{12} & U_{13} & U_{14} \\ 0 & 1 & U_{23} & U_{24} \\ 0 & 0 & 1 & U_{34} \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Decomposição LU usando o método de Crout

- A execução da multiplicação matricial no lado direito da equação resulta em

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} = \begin{bmatrix} L_{11} & (L_{11}U_{12}) & (L_{11}U_{13}) & (L_{11}U_{14}) \\ L_{21} & (L_{21}U_{12}+L_{22}) & (L_{21}U_{13}+L_{22}U_{23}) & (L_{21}U_{14}+L_{22}U_{24}) \\ L_{31} & (L_{31}U_{12}+L_{32}) & (L_{31}U_{13}+L_{32}U_{23}+L_{33}) & (L_{31}U_{14}+L_{32}U_{24}+L_{33}U_{34}) \\ L_{41} & (L_{41}U_{12}+L_{42}) & (L_{41}U_{13}+L_{42}U_{23}+L_{43}) & (L_{41}U_{14}+L_{42}U_{24}+L_{43}U_{34}+L_{44}) \end{bmatrix}$$

- Os elementos das matrizes L e U podem ser determinados com facilidade, linha após linha, igualando os elementos correspondentes em ambos os lados da equação.
- Os elementos de L e U são calculados da seguinte maneira:
  Passo 1: Cálculo da primeira coluna de L. Para $i = 1, \ldots, n$,

$$L_{i1} = a_{i1}$$

Decomposição LU usando o método de Crout

Passo 2: Para $i = 1, \ldots, n$, $U_{ii} = 1$

Passo 3: Cálculo dos elementos da primeira linha de U (exceto U_{11}). Para $j = 2, \ldots, n$,

$$U_{1j} = \frac{a_{1j}}{L_{11}}$$

Passo 4: Cálculo dos demais elementos linha após linha. Os elementos de L são calculados primeiro.

para $i = 2, 3, \ldots, n$

para $j = 2, 3, \ldots, i$

$$L_{ij} = a_{ij} - \sum_{k=1}^{k=j-1} L_{ik} U_{kj}$$

para $j = (i+1), (i+2), \ldots, n$

$$U_{ij} = \frac{a_{ij} - \sum_{k=1}^{k=i-1} L_{ik} U_{kj}}{L_{ii}}$$

Decomposição LU usando o método de Crout

Exemplo 1:

Determine as correntes i_1, i_2, i_3 e i_4 no circuito mostrado na figura (que é igual à Fig. 4-1). Escreva o sistema de equações a ser resolvido na forma $[a][i] = [b]$. Resolva o sistema usando o método de decomposição LU e faça a decomposição empregando o método de Crout.

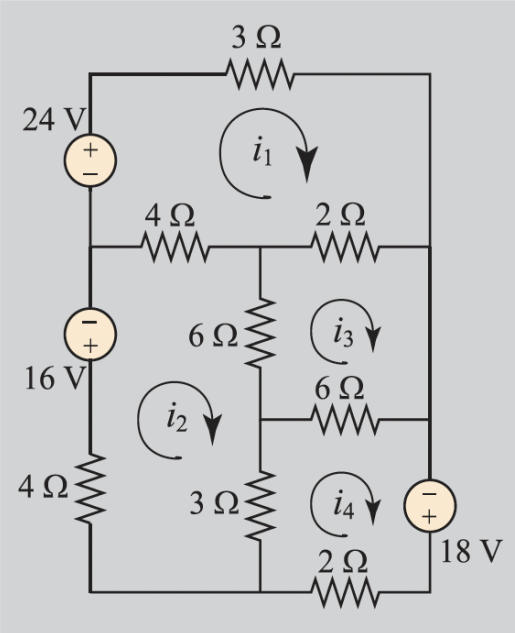

SOLUÇÃO

As correntes são determinadas a partir do conjunto de quatro equações dado na Eq. (4.1). As equações são deduzidas com o emprego da lei de Kirchhoff. Na forma matricial, $[a][i] = [b]$, as equações são:

$$\begin{bmatrix} 9 & -4 & -2 & 0 \\ -4 & 17 & -6 & -3 \\ -2 & -6 & 14 & -6 \\ 0 & -3 & -6 & 11 \end{bmatrix} \begin{bmatrix} i_1 \\ i_2 \\ i_3 \\ i_4 \end{bmatrix} = \begin{bmatrix} 24 \\ -16 \\ 0 \\ 18 \end{bmatrix} \tag{4.44}$$

Matriz Inversa

Se A é uma matriz e X é a inversa de A, então $A \cdot X = I$.

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} \begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \\ x_{41} & x_{42} & x_{43} & x_{44} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Logo,

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} \begin{bmatrix} x_{11} \\ x_{21} \\ x_{31} \\ x_{41} \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \quad \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} \begin{bmatrix} x_{12} \\ x_{22} \\ x_{32} \\ x_{42} \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} \begin{bmatrix} x_{13} \\ x_{23} \\ x_{33} \\ x_{43} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \quad \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} \begin{bmatrix} x_{14} \\ x_{24} \\ x_{34} \\ x_{44} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

Matriz Inversa

Cálculo da inversa com o método de decomposição LU

- O método de decomposição LU é especialmente adequado para o cálculo da inversa de uma matriz, pois a matriz de coeficientes nos quatro sistemas de equações é a mesma. Logo, a decomposição LU da matriz A é calculada apenas uma vez.

Cálculo da inversa com o método de Gauss-Jordan

- O método de Gauss-Jordan é facilmente adaptado incorporando de uma matriz identidade I de mesmo tamanho da matriz A. Em seguida, o procedimento de Gauss-Jordan é aplicado.

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} & 1 & 0 & 0 & 0 \\ a_{21} & a_{22} & a_{23} & a_{24} & 0 & 1 & 0 & 0 \\ a_{31} & a_{32} & a_{33} & a_{34} & 0 & 0 & 1 & 0 \\ a_{41} & a_{42} & a_{43} & a_{44} & 0 & 0 & 0 & 1 \end{bmatrix} \xrightarrow{\text{Procedimento de Gauss-Jordan}} \begin{bmatrix} 1 & 0 & 0 & 0 & a'_{11} & a'_{12} & a'_{13} & a'_{14} \\ 0 & 1 & 0 & 0 & a'_{21} & a'_{22} & a'_{23} & a'_{24} \\ 0 & 0 & 1 & 0 & a'_{31} & a'_{32} & a'_{33} & a'_{34} \\ 0 & 0 & 0 & 1 & a'_{41} & a'_{42} & a'_{43} & a'_{44} \end{bmatrix}$$

Decomposição de Cholesky

- Uma matriz simétrica é tal que $a_{ij} = a_{ji}$ $(A = A^T)$.
- Oferecem vantagens computacionais, pois apenas metade do armazenamento é necessária.
- O algoritmo é baseado no fato de que uma matriz simétrica pode ser decomposta em

$$A = L \cdot L^T$$

- Os termos da equação podem ser multiplicados e igualados, i. é, os fatores triangulares resultantes são transpostos um do outro.
- O resultado é expresso de forma simples por relações de recorrência.

Decomposição de Cholesky

Para a k-ésima linha,

$$l_{ki} = \frac{a_{ki} - \sum_{j=1}^{i-1} l_{ij} l_{kj}}{l_{ii}} \qquad \text{para } i = 1, 2, \ldots, k-1 \tag{11.3}$$

e

$$l_{kk} = \sqrt{a_{kk} - \sum_{j=1}^{k-1} l_{kj}^2} \tag{11.4}$$

Exemplo 2: Aplique a decomposição de Cholesky à matriz simétrica

$$A = \begin{bmatrix} 6 & 15 & 55 \\ 15 & 55 & 225 \\ 55 & 255 & 979 \end{bmatrix}$$

Decomposição de Cholesky

Solução. Para a primeira linha ($k = 1$), a Equação (11.3) não se aplica e a Equação (11.4) é usada para calcular

$$l_{11} = \sqrt{a_{11}} = \sqrt{6} = 2{,}4495$$

Para a segunda linha ($k = 2$), a Equação (11.3) dá

$$l_{21} = \frac{a_{21}}{l_{11}} = \frac{15}{2{,}4495} = 6{,}1237$$

e a Equação (11.4) fornece

$$l_{22} = \sqrt{a_{22} - l_{21}^2} = \sqrt{55 - (6{,}1237)^2} = 4{,}1833$$

Para a terceira linha ($k = 3$), a Equação (11.3) dá ($i = 1$)

$$l_{31} = \frac{a_{31}}{l_{11}} = \frac{55}{2{,}4495} = 22{,}454$$

e ($i = 2$)

$$l_{32} = \frac{a_{32} - l_{21}l_{31}}{l_{22}} = \frac{225 - 6{,}1237(22{,}454)}{4{,}1833} = 20{,}916$$

e a Equação (11.4) fornece

$$l_{33} = \sqrt{a_{33} - l_{31}^2 - l_{32}^2} = \sqrt{979 - (22{,}454)^2 - (20{,}916)^2} = 6{,}1106$$

Assim, a decomposição de Cholesky fornece

$$[L] = \begin{bmatrix} 2{,}4495 & & \\ 6{,}1237 & 4{,}1833 & \\ 22{,}454 & 20{,}916 & 6{,}1106 \end{bmatrix}$$

Condição para a convergência

- Deve-se observar que pode resultar em um erro de execução se o cálculo de a_{kk} envolver a extração da raiz quadrada de um número negativo.
- Quando a matriz é positiva definida[2], isso nunca vai ocorrer.
- Como muitas das matrizes simétricas que surgem na engenharia são, de fato, positivas definidas, o algoritmo de Cholesky tem vasta aplicação.
- Outra vantagem de lidar com matrizes simétricas positivas definidas é que pivotamento não é necessário para evitar a divisão por zero.

[2] Uma matriz é positiva definida quando todos os seus autovalores são positivos ou quando a forma quadrática $x^T Ax$ resulta num valor positivo para qualquer vetor x não nulo.

Métodos Iterativos

- Sistemas de equações lineares também podem ser resolvidos com o uso de uma abordagem iterativa.
- A forma explícita de um sistema de equações é

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + a_{14}x_4 &= b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + a_{24}x_4 &= b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + a_{34}x_4 &= b_3 \\ a_{41}x_1 + a_{42}x_2 + a_{43}x_3 + a_{44}x_4 &= b_4 \end{aligned}$$

Escrevendo as equações em uma forma explícita $\longrightarrow$

$$\begin{aligned} x_1 &= [b_1 - (a_{12}x_2 + a_{13}x_3 + a_{14}x_4)]/a_{11} \\ x_2 &= [b_2 - (a_{21}x_1 + a_{23}x_3 + a_{24}x_4)]/a_{22} \\ x_3 &= [b_3 - (a_{31}x_1 + a_{32}x_2 + a_{34}x_4)]/a_{33} \\ x_4 &= [b_4 - (a_{21}x_1 + a_{42}x_2 + a_{43}x_3)]/a_{44} \end{aligned}$$

- O processo de solução começa com a escolha de valores iniciais para as incógnitas.
- Em um sistema com n equações, as equações explícitas para as incógnitas x_i, para $i = 1, \ldots, n$, são

$$x_i = \frac{1}{a_{ii}} \left[b_i - \left(\sum_{j=1,\ j \neq i}^{j=n} a_{ij} x_j \right) \right]$$

Condição para a convergência

Critério das Linhas

- Para um sistema de n equações, uma condição suficiente para a convergência ocorre se

$$|a_{ii}| > \sum_{j=1,\ j\neq i}^{j=n} |a_{ij}|$$

- Essa condição é suficiente mas não necessária para a convergência do método iterativo.
  - Quando a condição é satisfeita, a matriz A é dita **diagonalmente dominante**, e o processo iterativo converge para a solução.
  - A solução pode convergir mesmo quando a condição não é satisfeita.

Método de Gauss-Jacobi

- No método de Jacobi, um valor inicial é escolhido para as incógnitas $x_1^{(1)}, x_2^{(1)}, \ldots, x_n^{(1)}$ (pode ser o vetor nulo).
- A (k + 1)-ésima estimativa $x_1^{(k+1)}, x_2^{(k+1)}, \ldots, x_n^{(k+1)}$ é calculada a partir da k-ésima estimativa $x_1^{(k)}, x_2^{(k)}, \ldots, x_n^{(k)}$.

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[b_i - \left(\sum_{j=1,\ j \neq i}^{j=n} a_{ij} x_j^{(k)} \right) \right]$$

$$\begin{cases} x_1^{(k+1)} = -a_{12}^* x_2^{(k)} - a_{13}^* x_3^{(k)} - \ldots - a_{1n}^* x_n^{(k)} + b_1^* \\ x_2^{(k+1)} = -a_{21}^* x_1^{(k)} - a_{23}^* x_3^{(k)} - \ldots - a_{2n}^* x_n^{(k)} + b_2^* \\ x_3^{(k+1)} = -a_{31}^* x_1^{(k)} - a_{32}^* x_2^{(k)} - \ldots - a_{3n}^* x_n^{(k)} + b_3^* \\ \ldots \ldots \\ x_n^{(k+1)} = -a_{n1}^* x_1^{(k)} - a_{n2}^* x_2^{(k)} - \ldots - a_{n,n-1}^* x_{n-1}^{(k)} + b_n^* \end{cases}$$

Método de Gauss-Jacobi

Critério de Parada: Quando o maior erro relativo de todas as incógnitas for menor que algum valor predeterminado, i. é.,

$$\max_{1 \leqslant i \leqslant n} \left| \frac{x_i^{(k+1)} - x_i^{(k)}}{x_i^{(k)}} \right| < \varepsilon$$

Exemplo 3: Resolva o sistema equações lineares usando o vetor nulo como valores iniciais e $\varepsilon < 10^{-5}$. (Solução exata: $x_1 = 5$, $x_2 = -2, x_3 = 2,5$ e $x_4 = -1$)

$$\begin{aligned} 9x_1 - 2x_2 + 3x_3 + 2x_4 &= 54,5 \\ 2x_1 + 8x_2 - 2x_3 + 3x_4 &= -14 \\ -3x_1 + 2x_2 + 11x_3 - 4x_4 &= 12,5 \\ -2x_1 + 3x_2 + 2x_3 + 10x_4 &= -21 \end{aligned}$$

Método de Gauss-Seidel

- O método de Gauss-Seidel converge mais rápido do que o método de Jacobi e requer menos memória computacional.
- No método de Gauss-Seidel, os valores atuais das incógnitas são utilizados no cálculo do novo valor da próxima incógnita.
- Em outras palavras, à medida que um novo valor é calculado, ele é imediatamente utilizado na próxima equação.

$$\begin{cases} x_1^{(k+1)} = -a_{12}^* x_2^{(k)} - a_{13}^* x_3^{(k)} - \ldots - a_{1n}^* x_n^{(k)} + b_1^* \\ x_2^{(k+1)} = -a_{21}^* x_1^{(k+1)} - a_{23}^* x_3^{(k)} - \ldots - a_{2n}^* x_n^{(k)} + b_2^* \\ x_3^{(k+1)} = -a_{31}^* x_1^{(k+1)} - a_{32}^* x_2^{(k+1)} - \ldots - a_{3n}^* x_n^{(k)} + b_3^* \\ \ldots \ldots \\ x_n^{(k+1)} = -a_{n1}^* x_1^{(k+1)} - a_{n2}^* x_2^{(k+1)} - \ldots - a_{n,n-1}^* x_{n-1}^{(k+1)} + b_n^* \end{cases}$$

Método de Gauss-Seidel

A fórmula método de Gauss-Seidel é dado por

$$x_1^{(k+1)} = \frac{1}{a_{11}}\left[b_1 - \sum_{j=2}^{j=n} a_{1j}x_j^{(k)}\right]$$

$$x_i^{(k+1)} = \frac{1}{a_{ii}}\left[b_i - \left(\sum_{j=1}^{j=i-1} a_{ij}x_j^{(k+1)} + \sum_{j=i+1}^{j=n} a_{ij}x_j^{(k)}\right)\right] \quad i = 2, 3, \ldots, n-1$$

$$x_n^{(k+1)} = \frac{1}{a_{nn}}\left[b_n - \sum_{j=1}^{j=n-1} a_{nj}x_j^{(k+1)}\right]$$

Exemplo 4: Use o mesmo sistema e condições do Exemplo 3.

Condição para a convergência

- Além da matriz A ser diagonalmente dominante, o Método de Gauss-Seidel também converge é a matriz satisfaz o critério de Sassenfeld.
- **Critério de Sassenfeld:** Dado o sistema de equações lineares $Ax = b$, então

$$\beta_1 = \frac{|a_{12}| + |a_{13}| + \ldots + |a_{1n}|}{|a_{11}|}$$

e para $j = 2, \cdots, n$, temos

$$\beta_j = \frac{|a_{j1}| \cdot \beta_1 + \ldots + |a_{j\ j-1}| \cdot \beta_{j-1} + |a_{j\ j+1}| + \ldots + |a_{jn}|}{|a_{jj}|}$$

Condição para a convergência

- Se
$$\max_{j=1,\ldots,n} |\beta_j| < 1$$
então o Método de Gauss-Seidel converge para a solução do sistema.
- Quando menor for o valor de β mais rápida será a convergência.
- Note que se a matriz A satisfaz o critério de Sassenfeld, automaticamente satisfaz o critério das linhas, mas o inverso não é verdadeiro.
- Também pode ser usando o critério de Sassenfeld nas colunas.

Aprimoramento da Convergência Usando Relaxamento

- O relaxamento representa uma pequena modificação no método de Gauss-Seidel e foi criado para melhorar a convergência.
- Após cada novo valor de x ser calculado, esse valor é modificado por uma média ponderada dos resultados da iteração anterior e da atual:

$$x_i^{(k+1)} = \omega x_i^{(k+1)} + (1-\omega)x_i^{(k)}$$

  onde ω é um fator de peso para o qual deve ser escolhido um valor entre 0 e 2.
- Se $\omega = 1$, então $(1-\omega) = 0$ e o resultado não é modificado.
- Se a ω for atribuído um valor entre 0 e 1, o resultado é uma média ponderada do resultado atual e do anterior.

Aprimoramento da Convergência Usando Relaxamento

- Essa modificação é chamada **sub-relaxamento** e é usado para fazer com que um sistema não-convergente passe a convergir, ou para apressar a convergência amortecendo as oscilações.
- Se $\omega \in (1, 2]$, peso extra é colocado no valor atual.
- Nesse caso, existe uma suposição implícita de que o novo valor está movendo-se na direção correta da solução verdadeira, mas a uma taxa muito lenta.
- Assim, o peso extra ω se presta a melhorar a estimativa aproximando do valor verdadeiro.
- Esse tipo de modificação é chamado **sobre-relaxamento**, e é implementado para acelerar a convergência de um sistema já convergente.
- Essa abordagem é também chamada de sobre-relaxamento simultâneo (ou sucessivo) ou SOR.

Normas de Matrizes

- A norma é um número real positivo atribuído a uma matriz ou a um vetor e fornece uma medida do tamanho ou comprimento.
- A norma infinita (linha) de uma matriz é dada por

$$||A||_\infty = \max_{1 \leqslant i \leqslant n} \sum_{j=1}^{n} |a_{ij}|$$

- A norma 1 (coluna) de uma matriz é dada por

$$||A||_1 = \max_{1 \leqslant j \leqslant n} \sum_{i=1}^{n} |a_{ij}|$$

Normas de Matrizes

- A norma Euclidiana de uma matriz é dada por

$$||A||_E = \left(\sum_{i=1}^{n} \sum_{j=1}^{n} |a_{ij}^2| \right)^{1/2}$$

- O **raio espectral** de uma matriz quadrada A, denotado por $\rho(A)$, é o máximo do módulo de todos os seus autovalores. Ele representa um limite superior para as normas matriciais e tem aplicações diretas no estudo da convergência de sequências de potências de matrizes e em análises de sistemas dinâmicos.
- O raio espectral é sempre menor ou igual a qualquer norma matricial consistente, i.é., $\rho(A) \leqslant ||A||$.

Normas de Matrizes

Exemplo 5: Dada a matriz

$$A = \begin{bmatrix} 1 & -2 & 0 \\ 3 & 4 & -1 \\ 2 & -1 & 5 \end{bmatrix}$$

Portanto,

- $||A||_\infty = 8$
- $||A||_1 = 7$
- $||A||_E = \sqrt{61} \approx 7,81$
- $\rho(A) = \max |\lambda_i|$, onde λ_i são ao autovalores de A.

Erro e Resíduo

- Se $\tilde{x}$ é uma solução numérica aproximada de um sistema $A \cdot x = b$ e x_R é a solução exata, então o **erro real** é

$$e = x_R - \tilde{x}$$

- Quando a solução exata não é conhecida, o erro real não pode ser calculado. Uma medida alternativa é calcular o **resíduo** r, definido por

$$r = b - A \cdot \tilde{x}$$

- Se a solução numérica for próxima da solução real, então todos os elementos de r são pequenos.

Erro e Resíduo

Exemplo 6: A solução exata do sistema

$$\begin{aligned} 1,02x_1 + 0,98x_2 &= 2 \\ 0,98x_1 + 1,02x_2 &= 2 \end{aligned}$$

é $x_1 = x_2 = 1$. Se a solução aproximada for $x_1 = 2$ e $x_2 = 0$, então

$$e = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$$r = \begin{bmatrix} 2 \\ 2 \end{bmatrix} - \begin{bmatrix} 1,02 & 0,98 \\ 0,98 & 1,02 \end{bmatrix} \cdot \begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} -0,04 \\ 0,04 \end{bmatrix}$$

Este exemplo mostra que um resíduo pequeno não necessariamente garante um erro pequeno. O fato de um resíduo pequeno resultar ou não em um erro pequeno depende da "magnitude"[3] de A.

[3] Diferente de um vetor, que tem uma definição única e intuitiva de magnitude (comprimento), uma matriz pode ter sua "magnitude" medida de várias formas, dependendo da norma aplicada.

Condicionamento de Sistemas Lineares

- A maioria dos processos numéricos seguem a seguinte linha geral:
  1. Dados são fornecidos
  2. Os dados são processados de acordo com um plano pré-estabelecido (algoritmo)
  3. Resultados são produzidos.
- Sistemas **mal condicionados** são aqueles para os quais pequenas mudanças nos coeficientes (matriz A ou vetor B) resultam em grandes mudanças nas soluções (vetor x).
- Vamos analisar como pertubações nos dados podem ou não influenciar os resultados.

Condicionamento de Sistemas Lineares

Exemplo 7: O sistema

$$\begin{cases} x + y = 2 \\ x + 1.01y = 2.01 \end{cases}$$

tem solução $x = y = 1$. Se na segunda equação mudarmos 2.01 para 2.02, obtemos que a solução do sistema $x = 0$ e $y = 2$. Portanto uma pequena mudança nos dados produz uma grande mudança no resultado.

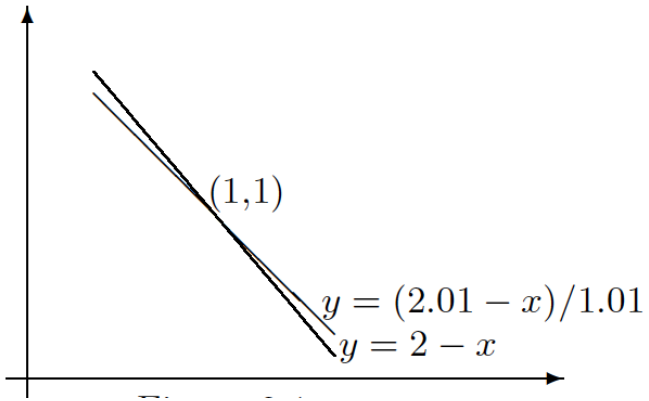

Condicionamento de Sistemas Lineares

- **Mal condicionamento** está relacionado ao fato de que a matriz dos coeficientes nas equações lineares está próxima de ser singular[4].
- O conceito de norma pode ser usado para definir o **número de condicionamento da matriz**, dado por

$$Cond\ (A) = ||A|| \cdot ||A^{-1}||$$

- O número condição da matriz identidade é igual a 1.
- O número condição de qualquer outra matriz é maior ou igual a 1.
- Para uma dada matriz, o valor do número condição depende da norma matricial utilizada.

[4] Uma matriz singular é quadrada cujo determinante é zero, i.é., não tem uma matriz inversa.

Condicionamento de Sistemas Lineares

Exemplo 6: Use a norma infinito para fazer uma estimativa do número de condicionamento da matriz de Hilbert 3×3

$$H = \begin{bmatrix} 1 & 1/2 & 1/3 \\ 1/2 & 1/3 & 1/4 \\ 1/3 & 1/4 & 1/5 \end{bmatrix}$$

Podemos mudar a escala da matriz de modo que o maior elemento em cada linha seja 1

$$H = \begin{bmatrix} 1 & 1/2 & 1/3 \\ 1 & 2/3 & 1/2 \\ 1 & 3/4 & 3/5 \end{bmatrix}$$

A terceira linha tem a maior soma, então $||H||_\infty = 2,35$.

Condicionamento de Sistemas Lineares

A inversa da matriz com mudança de escala é

$$H^{-1} = \begin{bmatrix} 9 & -18 & 10 \\ -36 & 96 & -60 \\ 30 & -90 & 60 \end{bmatrix}$$

A segunda linha tem a maior soma, então $||H^{-1}||_\infty = 192$.
Logo, o número de condicionamento pode ser calculado por

$$Cond\ (A) = ||H||_\infty \cdot ||H^{-1}||_\infty = 2,35 \cdot 192 = 451,2$$

O fato de o número de condicionamento ser consideravelmente maior do que a unidade, sugere que o sistema é mal condicionado.

Aplicação na Engenharia Elétrica

- Na Engenharia Elétrica, sistemas de equações lineares representam conjuntos de equações que modelam relações entre tensões, correntes e outros parâmetros elétricos, sendo fundamentais na análise e resolução de circuitos.

- Eles aparecem na aplicação das Leis de Kirchhoff, análise de circuitos, sistemas de potência, eletrônica e métodos numéricos, permitindo determinar o comportamento do sistema e a distribuição de correntes e tensões.